

La aplicación de Redes Neuronales Artificiales (RNA): a la recuperación de la información

Félix de Moya Anegón
Universidad de Granada (Granada)
felix@goliat.ugr.es

Víctor Herrero Solana
Universidad Nacional
de Mar del Plata (Argentina)
victorhs@platon.ugr.es

Vicente Guerrero Bote
Universidad de Extremadura (Badajoz)
vicente@alcazaba.unex.es

RESUM

En els darrers temps s'ha definit un nou camp de les ciències de la computació, comprès per aquells mètodes i tècniques de resolució de problemes que no poden ser fàcilment descrits per algorismes tradicionals. Aquest camp, anomenat «computació cognitiva» o «computació del món real», disposa d'un conjunt variat de metodologies de treball, tals com: la lògica difusa, el raonament aproximat, els algorismes genètics, la teoria del caos i les Xarxes Neuronals Artificials (XNA). L'objectiu del present treball és introduir a la problemàtica d'aquestes darreres: definicions, principis i tipologia, així com també les aplicacions concretes en el camp de la recuperació de la informació.

RESUMEN

En los últimos tiempos se ha venido definiendo un nuevo campo de las ciencias de la computación, comprendido por aquellos métodos y técnicas de resolución de problemas que no pueden ser fácilmente descritos por algoritmos tradicionales. Este campo, denominado «computación cognitiva» o «computación del mundo real», dispone de un conjunto variado de metodologías de trabajo, tales como: la lógica difusa, el razonamiento aproximado, los algoritmos genéticos, la teoría del caos y las Redes Neuronales Artificiales (RNA). El objetivo del presente trabajo es introducir a la problemática de estas últimas: definiciones, principios y tipología, así como también las aplicaciones concretas en el campo de la recuperación de la información.

Introducción

Durante la pasada década en el campo de la recuperación de la información se ha experimentado con diversas técnicas de Inteligencia Artificial (IA) basadas en reglas y conocimiento. Estas técnicas parecen tener muchas limitaciones y dificultades de aplicación, por lo que ya en la presente década se ha comenzado a trabajar con las técnicas de IA más recientes, basadas en el aprendizaje inductivo: el aprendizaje simbólico, los algoritmos genéticos y las redes neuronales (Chen, 1995).

Los primeros trabajos en computación neuronal se remontan a principios de los años 40. Un neurofísico llamado Warren McCulloch y un matemático llamado Walter Pitts propusieron, en base a sus estudios del sistema nervioso, un modelo de neurona formal implementada mediante circuitos eléctricos (McCulloch, 1943). El entusiasmo que despertó el modelo neuronal impulsó la investigación en esta línea durante los años 50 y 60. En 1957 Frank Rosenblatt desarrolló el Perceptrón, un modelo de red que posee la capacidad de generalización, por lo que se ha utilizado hasta el día de hoy en diversas aplicaciones, generalmente en el reconocimiento de patrones. En 1959 Bernard Widrow y Marcial Hoff, de la Universidad de Stanford, desarrollaron el modelo ADALINE (ADaptive LINEar Elements), primera RNA aplicada a un problema real (filtros de ruidos en líneas telefónicas).

En 1969 Marvin Minsky y Seymour Papert, del MIT, publicaron una obra en la que atacan al modelo neural y consideran que cualquier investigación en esa línea era estéril (Minsky, 1969). Debido a esta crítica los trabajos sobre RNA se detienen hasta un nuevo impulso durante los años 80. A pesar de esta pausa, varios investigadores siguieron trabajando en esa dirección durante los años 70. Tal es el caso del estadounidense James Anderson que desarrolla el modelo BSB (Brain-State-in-a-Box), o del finlandés Teuvo Kohonen que hace lo propio con uno basado en mapas auto-organizativos.

A partir de 1982 el interés por la computación neuronal comenzó a cobrar fuerza nuevamente. El avance logrado en *hardware* y *software*, los avances metodológicos en torno a los algoritmos de aprendizaje para RNA, y las nuevas técnicas de inteligencia artificial, favorecieron este renacimiento. Ese mismo año se realiza la primera conferencia entre investigadores de computación neuronal de EEUU y Japón. En 1985 el Instituto Americano de Física establece la reunión anual *Neural Networks for Computing*. En 1987 el IEEE celebró la primera conferencia internacional sobre RNA. Ese mismo año se crea la Sociedad Internacional de Redes Neuronales (INNS).

Durante los años 90, las RNA comienzan a ser aplicadas a distintos campos del conocimiento: clasificación de patrones, robótica, visión artificial, procesamiento de señales, reconocimiento de escritura y habla, etc. En este contexto, las aplicaciones documentales no han podido quedar al margen de este proceso.

1. Definición y características

Una RNA puede definirse como un sistema de procesamiento de información compuesto por un gran número de elementos de procesamiento (neuronas), profusamente conectados entre sí a través de canales de comunicación (Reguero, 1995). Estas conexiones establecen una estructura jerárquica y permiten la interacción con los objetos del mundo real tratando de emular al sistema nervioso biológico. A diferencia de la computación tradicional, basada en algoritmos predecibles, la computación neuronal permite desarrollar sistemas que resuelvan problemas complejos cuya formalización matemática es sumamente difícil. Esto se logra gracias a los principios de funcionamiento de las RNA, de los cuales citamos a continuación los cinco más importantes (Hilera, 1995):

- *Aprendizaje adaptativo*: esta es quizás la característica más importante de las RNA, ya que pueden comportarse en función de un entrenamiento con una serie de ejemplos ilustrativos. De esta forma, no es necesario elaborar un modelo *a priori*, ni establecer funciones probabilísticas. Una RNA es adaptativa porque puede modificarse constantemente con el fin de adaptarse a nuevas condiciones de trabajo.
- *Autoorganización*: mientras que el aprendizaje es un proceso donde se modifica la información interna de la RNA, la autoorganización consiste en la modificación de toda la red completa con el fin de llevar a cabo un objetivo específico. Autoorganización significa generalización, de esta forma una red puede responder a datos o situaciones que no ha experimentado antes, pero que puede inferir en base a su entrenamiento. Esta característica es muy útil sobre todo cuando la información de entrada es poco clara o se encuentra incompleta.
- *Tolerancia a fallos*: en la computación tradicional la pérdida de un fragmento pequeño de información puede acarrear comúnmente la inutilización del sistema. Las RNA poseen una alta capacidad de tolerancia a fallos. La tolerancia a fallos se entiende aquí en dos sentidos: primero, las redes pueden reconocer patrones de información con ruido, distorsión o incompletos (tolerancia de fallos respecto de los datos); y segundo, pueden seguir trabajando (con cierta degradación) aunque se destruya parte de la red (tolerancia a fallos respecto de la estructura). La explicación de este fenómeno se encuentra en que, mientras la computación tradicional almacena la información en espacios únicos, localizados y direccionables, las redes neuronales lo hacen de forma distribuida y con un alto grado de redundancia.
- *Operación en tiempo real*: de todos los métodos existentes, las RNA son las más indicadas para el reconocimiento de patrones en tiempo real, debido a que trabajan en paralelo actualizando todas sus instancias simultáneamente. Es importante destacar que esta característica solo se aprecia cuando se implementan redes con hardware especialmente diseñado para el procesamiento en paralelo.
- *Fácil inserción en la tecnología existente*: es relativamente sencillo obtener chips especializados para redes neuronales que mejoran su capacidad en ciertas tareas. Ello facilita la integración modular en los sistemas existentes.

1.1. Elementos de una RNA

Las RNA son modelos de procesamiento de información basados en el funcionamiento del cerebro humano. Están formadas por una gran cantidad de unidades o elementos de procesamiento llamados neuronas, las cuales podemos dividir en tres grupos diferentes: 1) aquellas que reciben la información del exterior, también denominadas como neuronas de entradas; 2) aquellas que transmiten información al exterior, denominadas neuronas de salida, y por último aquellas que no tienen ningún contacto con el exterior y solamente intercambian informa-

ción con otras neuronas de la red, a estas se las llama neuronas ocultas. En cualquier tipo de RNA las neuronas se encuentran fuertemente interconectadas entre sí, organizándose por capas y formando diferentes topologías. Existen diferentes topologías para resolver diferentes tipos de problemas.

En la figura 1 podemos apreciar un diagrama esquemático de una neurona (Regueiro, 1995). Cuenta con una cantidad variable de entradas ($X_0 \dots X_{Q+M}$) que provienen del exterior (en el caso de que nuestra neurona se encuentre en la capa de entrada de la red), o de otras neuronas (si se encuentra en alguna capa oculta o la de salida). A su vez dispone de una sola salida (X) que transmitirá la información hacia el exterior (en el caso de que nuestra neurona se encuentre en la capa de salida de la red), o hacia otras neuronas (si se encuentra en la capa de entrada o en alguna oculta). La señal de salida se calculará en función de las de entradas, para lo cual cada una de ellas es afectada por un determinado peso ($w_{j0} \dots w_{jQ+M}$). Estos pesos varían libremente en función del tiempo y en cada una de las neuronas que forman parte de la red, y esto es sumamente importante debido a que el conocimiento que contiene la red estará en dichos pesos. Todas las señales de entrada se combinan mediante la denominada función de combinación (f_j), que puede variar según el tipo de neurona pero que siempre generará un vector cuyos componentes determinarán el valor de final salida mediante la función de activación (g_j). También existen diferentes tipos de funciones de activación, las más comunes son: función escalón, función lineal o mixta, sigmoideal, y función gaussiana. Cada función posee sus propias características, y serán utilizadas según el tipo de información que vayamos a manejar (p.ej. binaria o analógica, etc.).




Figura 1. Representación esquemática de una neurona (Hilera, 1995)

Como ya habíamos afirmado, al igual que en el sistema nervioso humano, el conocimiento se encuentra en los pesos de las conexiones entre neuronas, y no en las neuronas en sí. Estos pesos no tienen valor constante, sino que van variando en función de un determinado algoritmo denominado regla de aprendizaje. Una regla de aprendizaje hace variar el valor de los pesos de una red hasta que estos adoptan un valor constante, cuando ello ocurre se dice que la red ya ha «aprendido». Existen muchas reglas de aprendizaje diferentes, pero podríamos dividir las en dos grandes grupos: 1) las de aprendizaje supervisado, y 2) las de aprendizaje no supervisado. En las primeras existe una muestra de información que sirve de ejemplo para que la red aprenda, mientras que en las segundas no existe esta información y los pesos de la red fluctúan libremente sin ningún tipo de referente, hasta que logran estabilizarse.

Dentro de cada uno de estos dos grupos, existen varios algoritmos determinados que no nombraremos aquí y que se encuentran asociados a diferentes modelos de red. Por último podemos decir que existe otro criterio de clasificación de reglas de aprendizaje, que está relacionado con forma de operación de la instrucción: 1) *off-line*, y 2) *on-line*. En el primer caso, la red debe desconectarse de su funcionamiento hasta que el aprendizaje termine, para luego establecer de forma fija sus pesos y comenzar a operar. En el segundo caso, el aprendizaje se efectúa durante el funcionamiento normal de la red, por lo que aquí no se diferencia la fase de aprendizaje de la de operación. La principal diferencia entre las dos estará en las redes *off-line* serán más estables en su funcionamiento que las *on-line*.

1.2. Estructura de una RNA

Ya hemos visto como esta compuesto un elemento de procesamiento o neurona (microestructura). Conectando varias neuronas de un determinado modo conseguimos una red (mesoestructura). Existen infinitas variaciones de topologías, pero podemos clasificarlas según cuatro criterios: 1) número de niveles o capas, 2) número de neuronas por nivel, y 3) formas de conexión.




Figura 2. Estructura de una RNA multicapa (Hilera, 1995)

En cuanto a la cantidad de capas, podemos decir que una red puede estar formada por un mínimo de una capa y un máximo de n capas. Cuando existe una sola capa, esta oficia tanto de entrada como de salida. En el caso de una red de dos capas, la primera será de entrada y la segunda de salida. Para el caso de redes con más de tres capas, como la de la figura 2: la primera será de entrada, la última de salida y las restantes serán las capas ocultas que mencionábamos más arriba. El número de neuronas por nivel puede variar desde 1 hasta n , y depende de la topología de cada modelo en particular.




Figura 3. Red con propagación hacia atrás (Hilera, 1995)

La forma en que la salida de una determinada capa de neuronas está conectada a la entrada de otra, determina la conectividad de la red. Aquí existen dos formas básicas: 1) cuando ninguna salida de una capa es entrada del mismo nivel o de niveles anteriores, denominada propagación hacia adelante (figura 2), y 2) cuando existe algún tipo de realimentación de las salidas a las entradas anteriores o del mismo nivel, denominada propagación hacia atrás (figura 3). Cada una de las características enumeradas no dice demasiado por sí sola, por lo que debe analizarse junto al modelo de red que la adopta, sin embargo, dicho análisis excede los objetivos del presente artículo.

2. Modelos de RNA

Como hemos repetido a lo largo del trabajo, existen varios modelos diferentes de redes neuronales. Cada una de ellos ha sido diseñado para fines más o menos específicos, no obstante, existen varios que han ganado gran popularidad. En el cuadro 1, presentamos modelos más conocidos junto a sus características (Hilera, 1995):

Nombre	Año	Aplicaciones	Comentarios	Limitaciones	Creador/es
Avalancha	1967	Reconocimiento de habla continua. Control de robots	Ninguna red sencilla realiza estas tareas	No es fácil alterar la velocidad o interpolar el movimiento	Stephen Grossberg
Teoría de resonancia adaptativa (ART)	1986	Reconocimiento de patrones (radar, sonar, etc.)	Sofisticada, poco utilizada	Sensible a la translación, distorsión y escala	Gail Carpenter, Stephen Grossberg
ADALINE/ MADALINE	1960	Filtrado de señales. Ecualizador adaptativo. Modems	Rápida, fácil de implementar con circuitos analógicos	Sólo es posible clasificar espacios linealmente separados	Bernard Widrow
Back Propagation	1974-1985	Síntesis de voz desde texto. Control de robots. Predicción Reconocimiento de patrones	La red más popular. Numerosas aplicaciones con éxito. Facilidad de preñdizaje. Potente.	Necesita mucho tiempo para el aprendizaje y muchos ejemplos	Paul Werbos, David Parker, David Rumelhart
Memoria asociativa bidireccional	1985	Memoria heteroasociativa de acceso por contenido	Aprendizaje y arquitectura simples	Baja capacidad almacenamiento. Los datos deben ser codificados	Bart Kosko
Máquinas de Boltzmann y Cauchy	1985-1986	Reconocimiento de patrones (imágenes, sonar y radar). Optimización	Redes simples Capacidad de representación óptima de patrones	La máquina de Boltzmann necesita un tiempo muy largo de aprendizaje	Jeffrey Hinton, Terry Sejnowski, Harold Szu
Brain-State-in-a-Box	1977	Extracción de conocimiento de bases de datos	Posiblemente mejor realización que las redes de Hopfield	Realización potenciales aplicaciones no estudiadas totalmente	James Anderson
Cerebellatron	1969	Control del movimiento de brazos de un robot	Semejante a Avalancha	Requiere complicadas entradas de control	David Marr, James Albus, Andres Pellionez
Counter-propagation	1986	Comprensión de imágenes	Combinación de Perceptrón y TPM	Numerosas neuronas y conexiones	Robert Hecht-Nielsen
Hopfield	1982	Reconstrucción de patrones y optimización	Puede implementarse en VLSI. Fácil de conceptualizar	Capacidad y estabilidad	John Hopfield
Neocognitron	1987-1984	Reconocimiento de caracteres manuscritos	Insensible a la translación, rotación y escala	Requiere muchos elementos de proceso, niveles y conexiones	K. Fukushima
Perceptron	1957	Reconocimiento de caracteres impresos	La red más antigua	No puede reconocer caracteres complejos	Frank Rosenblatt
Self-Organizing-Map (SOM)	1980-1984	Reconocimiento de patrones, codificación de datos, optimización	Realiza mapas de características comunes de los datos aprendidos	Requiere mucho entrenamiento	Teuvo Kohonen

Cuadro 1. Modelos de redes (Hilera, 1995)

3. El modelo de Kohonen

Antes de entrar de lleno a las aplicaciones de las RNA en el campo de la Documentación nos detendremos brevemente para analizar uno de los modelos del cuadro anterior más utilizados en recuperación de la información, se trata del desarrollado por Teuvo Kohonen. A principio de los años 80, Kohonen demostró que una información de entrada por sí sola, suponiendo una estructura propia y una descripción funcional del comportamiento de la red, era suficiente para forzar la formación de mapas topológicos (Kohonen, 1982). Estos mapas presentan la característica de organizar la información de entrada clasificándola automáticamente.

Este modelo presenta dos variantes: 1) la denominada «Cuantificación por Vector de Aprendizaje» (*Learning Vector Quantization*) o LVQ, y 2) la llamada «Mapa de Preservación Topológica» (*Topology-Preserving Map*) o TPM. A esta última también se la conoce comúnmente como «Mapa auto-organizativo» (*Self-Organizing Map*) o SOM. La diferencia entre ambos modelos radica en que mientras la LVQ trabaja con salidas en una sola dimensión, la salida en el SOM es bidimensional. Esta última es la que se encuentra más extendida.

El principio de funcionamiento de este modelo es sencillo, se trata de establecer una correspondencia entre la información de entrada y un espacio de salida de dos dimensiones, o mapa topológico. De esta manera, los datos de entrada con características comunes activarán zonas próximas del mapa. Es muy común representar este modelo de red con sus neuronas de salida dispuestas de manera bidimensional, como podemos observar en la figura 4. Cuando se ingresa un dato a la red esta reacciona de forma tal que solo una neurona de la capa de salida resulta activada. A esta neurona se la denomina vencedora (*winner-take-all unit*) y determina un punto en el mapa bidimensional. Lo que realmente está haciendo la red es clasificar la información de entrada, ya que la neurona ganadora representa la clase a la que pertenece la entrada, además de que ante entradas similares se activará siempre la misma neurona. Por tanto, la red es sumamente indicada para establecer relaciones, desconocidas previamente, entre un conjunto determinado de datos.




Figura 4. Modelo SOM con sus neuronas de salida formando el mapa


El método de aprendizaje del modelo SOM se denomina competitivo y es del tipo no supervisado y *off-line*, por lo que se contará con una etapa previa de entrenamiento y una posterior de operación. El modelo de Kohonen es una de las RNA más útiles que se han desarrollado, aunque posee dos limitaciones: 1) el proceso de aprendizaje suele ser largo y arduo, y 2) para aprender nuevos datos es necesario repetir el proceso de aprendizaje por completo. No obstante, la versatilidad de este tipo de red es muy amplia, lo que le permite clasificar todo tipo de información, desde la literaria (Honkela, 1995) hasta la económica (Kaski, 1995). Más adelante se verán distintas aplicaciones de este modelo.

4. Las RNA dentro de la literatura especializada en Documentación

El tema de las RNA es relativamente nuevo en el campo de la Documentación y a pesar de ello ha experimentado un gran auge en los últimos años. Un estudio realizado en la base de datos Library and Information Science Abstracts (LISA), en su edición Winter 1996, nos permite observar el abrupto crecimiento de la literatura especializada en dicha temática. Las referencias se recuperaron mediante la búsqueda del término «neural» en texto libre, la cual arrojó cerca de 200 entradas. De ahí se eliminaron las entradas correspondientes a investigaciones en curso y se dejaron solamente los artículos, reseñas y ponencias de congresos: 170 registros. Luego se ordenaron de forma temporal desde 1981 hasta 1996, y se construyó el gráfico de la figura 5. En él podemos observar

claramente el crecimiento exponencial de la literatura sobre el tema, especialmente en los períodos 1992-93 y 1994-95. La caída de 1996 no debe ser tomada en cuenta ya que la información sobre este año se encuentra incompleta, la cual estará disponible en ediciones posteriores.

Otro dato importante es el de los títulos de revistas involucrados en este estudio. En el cuadro 2 podemos apreciar los nombres de las publicaciones ordenados por su frecuencia de aparición. Es evidente que esta distribución se asemeja a la de la dispersión de Bradford, ya que cuenta con un núcleo de pocos títulos que acaparan un gran porcentaje de artículos mientras que por otro lado tenemos una gran cantidad de revistas con solo uno o dos artículos.



Lo curioso del estudio tal vez sea que la publicación más frecuente no está especializada en redes neuronales ni en inteligencia artificial, sino que proviene del campo químico. El *Journal of Chemical Information and Computer Sciences* cubre cerca del 25% de las referencias sobre el tema, por lo que podemos afirmar que la recuperación de la información química aparece como el segmento más activo en el estudio de las redes neuronales. Por detrás de ella aparecen distintos títulos especializados en sistemas expertos e inteligencia artificial, temáticas mucho más afines con las RNA, y que cubren un rango de entre el 1.5 y 7.5 % (*Experts Systems* 7.64%, *Knowledge-Based Systems* 5.88%, *IEEE Expert* 3.53%, *Artificial Intelligence Review* 2.94%, *Artificial Intelligence* 1.76%). No obstante, si sumáramos las referencias de todas estas revistas, aún no alcanzaríamos los números de la primera. En las restantes encontramos títulos de Informática en general (*Telematics and Informatics* 4.11%, *Byte* 2.35%), especializados en Recuperación de la Información (*Information Processing and Management* 3.53%, *Information Systems Management* 1.76%, y *Library Hi Tech* 1.76), una especializada en Biología y Medicina (*Computer in Biology and Medicine* 2.35%), y otra en Bibliometría (*Scientometrics* 2.94%). Detrás de ellas viene un pelotón compuesto por 48 revistas que presentan a lo sumo un par de artículos sobre el tema.

La última cuestión que debemos resaltar es el hecho de que la mayoría de los títulos especializados en Documentación y recuperación de la información, y que podríamos denominar como el núcleo duro de la especialidad, no aparecen o lo hacen con una o dos referencias. Aquí algunos ejemplos: *JASIS* dos referencias, *Journal of Information Science* dos, *ARIST* una, *ASLIB Proceedings* una, *Journal of Documentation* cero, y *Library Trends* cero. Esto nos estaría indicando que las RNA no son aún una temática plenamente abordada por la literatura de la disciplina y que si deseamos hacer un estudio sobre su aplicación a la recuperación de la información debemos prestar mucha atención a los trabajos que se encuentran en la frontera entre diversas disciplinas (Química, Biología, Inteligencia Artificial, etc.) y la Documentación.

Título de la publicación	Nº	%	Acu	% Acu
<i>Journal of Chemical Information and Computer Sciences</i>	41	24.11	41	24.11
<i>Experts Systems</i>	13	7.64	54	31.75
<i>Knowledge-Based Systems</i>	10	5.88	64	37.63
<i>Telematics and Informatics</i>	7	4.11	71	41.74
<i>IEEE Expert</i>	6	3.53	77	45.27
<i>Information Processing and Management</i>	6	3.53	83	48.8
<i>Artificial Intelligence Review</i>	5	2.94	88	51.74
<i>Scientometrics</i>	5	2.94	93	54.68
<i>Byte</i>	4	2.35	97	57.03
<i>Computer in Biology and Medicine</i>	4	2.35	101	59.38
<i>Artificial Intelligence</i>	3	1.76	104	61.14
<i>Information Systems Management</i>	3	1.76	107	62.9
<i>Library Hi Tech</i>	3	1.76	110	64.66
<i>12 títulos</i>	2	1.17	134	78.7
<i>36 títulos</i>	1	0.59	170	99.94

Cuadro 2. Títulos de revistas por frecuencia de aparición

Para un estudio más profundo de la bibliografía sobre redes neuronales, consultar el estudio bibliométrico de Van Rann (Raán, 1993). En él se presenta un mapa de la ciencia elaborado mediante el método de co-ocurrencia de términos en el campo temático.

5. Aplicaciones de las RNA

Las aplicaciones de RNA pueden clasificarse por diversos criterios. Nosotros utilizaremos una adaptación del esquema de Scholtes (1995), que contempla una ordenación por tipo de aplicación:

- Gestión bibliotecaria (*library management*)
- Clasificación de la información (*information clustering*)
- Diseño de interfase (*interface design*)
- Filtrado de información (*filtering of information*)
- Búsqueda incompleta (*incomplete searching*)
- Descubrimiento de información (*data mining*)

La enumeración de aplicaciones no pretende ser en ningún momento exhaustiva, y el nivel de detalle de cada una varía en función de la información disponible.

5.1. Gestión bibliotecaria (*library management*)

Existen pocas aplicaciones neuronales dirigidas a la gestión bibliotecaria. Pérez (1991) cita algunas, pero todas ellas tan solo son paquetes dirigidos hacia aplicaciones contables que han sido utilizados para predicción presupuestaria en bibliotecas. Para Scholtes (1995), las experiencias en este campo se centran en la gestión de préstamos y publicaciones periódicas. No obstante, indica que los trabajos en este campo son cada vez más raros. Esto se debe a que se ha llegado a la conclusión de que la información con la que se debe trabajar es demasiado precisa y estructurada, mientras que el rendimiento óptimo de las RNA se obtiene con datos desestructurados e incompletos.

5.2. Clasificación de la información (*information clustering*)

La clasificación automática de la información es el campo donde más se han aplicado las RNA, particularmente en la generación de mapas bidimensionales de conceptos.

5.2.1. Mapas de Xia Lin

Como ya hemos visto, una de las variantes del modelo de Kohonen es el de los mapas auto-organizados por características. Xia Lin, investigador de la Universidad de Kentucky y especialista en la representación gráfica de la información (Lin, 1991), utiliza estos mapas con el fin de generar una salida «visualizable» (*map display*) de una determinada colección de documentos (Lin, 1995 y 1997). Lin presenta tres ejemplos diferentes: 1) una serie de documentos extraídos de la base INSPEC a través de DIALOG, 2) una colección de documentos personales, y 3) un grupo de ponencias de la conferencia SIGIR (1990-93). Para cada uno de ellos, genera un mapa determinado mediante el siguiente procedimiento:

- Se construye una lista que incluya todos los términos que aparecen en los títulos y resúmenes de todos los documentos de la colección.
- Se eliminan los términos irrelevantes mediante una lista de palabras vacías (*stop list*).
- Se aplica a la lista un algoritmo de *stemming* para llevar los términos a su raíz y reducir su número. Luego se eliminan los duplicados.
- Se eliminan los términos con alta y baja frecuencia de aparición, conservando la zona media del espectro.
- Se crea un vector para cada documento de n dimensiones, tal que n es el número de términos que han quedado en la lista.
- Se completa cada vector con el peso asociado a cada término-documento. El peso se calcula como proporcional a la frecuencia del término en el documento e inverso a la frecuencia del término en toda la colección. En algunos ejemplos se prescinde de los pesos y solo se indica la presencia o no del término, mediante «1» y «0».
- Estos vectores se utilizan como entrada para entrenar una red de Kohonen con n elementos de entrada (tal que n sea igual a la cantidad de términos de cada vector), y un número variable de salidas (p.ej. $10 \times 14 = 140$ neuronas), que supondrá el tamaño del mapa de salida.
- Este mapa de salida estará representado también por un vector de pesos al que en un principio se le asignan valores pequeños y al azar.
- Durante el proceso de entrenamiento se tomará un vector-documento al azar. La neurona de salida cuyo vector se parezca más al vector-documento de entrada, será declarada neurona ganadora. Luego los pesos de esta neurona (y los de sus vecinas), serán ajustados para acercarse aún más a los valores del vector-documento.
- Este proceso se repite durante un determinado número de ciclos. Cuando el proceso de entrenamiento ha finalizado cada término se compara con los pesos de las neuronas de salida, de esta forma se asocia el término más cercano (*best-match term*) a cada una de las salidas. Conectando las neuronas de salida con similares términos asociados se generarán las diferentes áreas del mapa.
- Con esta matriz salida se construye un mapa como el que podemos apreciar en la figura 5, y que corresponde al segundo de los ejemplos de Lin: la bibliografía personal.

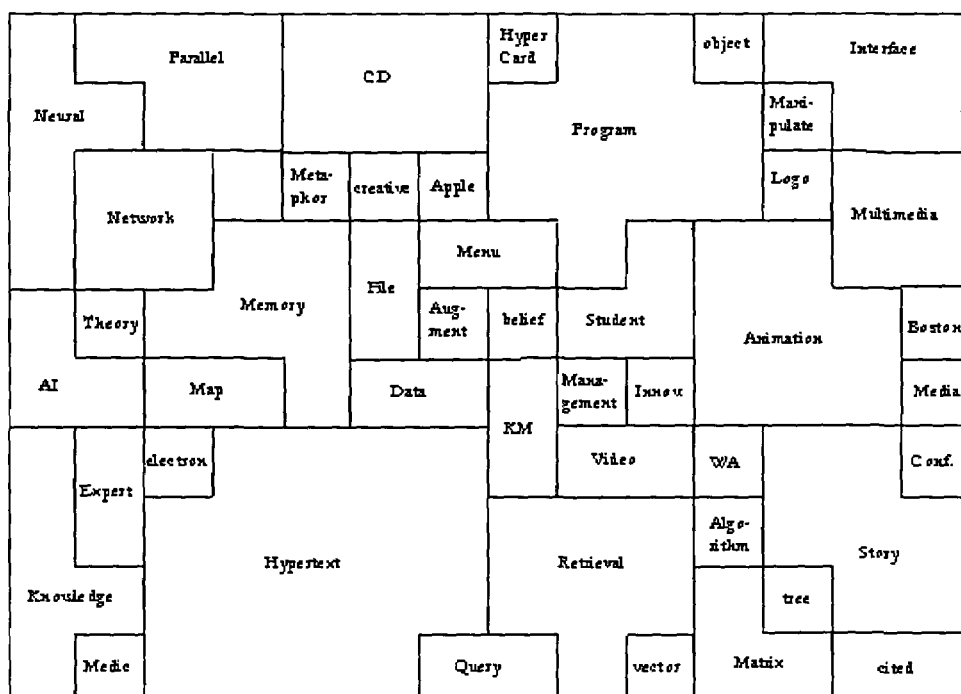


Figura 5. Mapa correspondiente a la bibliografía personal de Xia Lin (1997)

Al mapa de salida se le pueden añadir herramientas complementarias de visualización, para obtener diferentes niveles de resolución o menús desplegables (*pop-up*) para cada nodo. El objetivo de estos complementos es facilitar el examen y visualización de la información representada en el mapa.

Lin establece cuales son las limitaciones del modelo, entre las que se encuentran: incapacidad para trabajar con grandes volúmenes de información y alto costo de procesamiento de la información. No obstante, la aplicación de este modelo parece ser uno de los más prometedores en la clasificación automática mediante redes neuronales. Existen en la actualidad algunas aplicaciones que presentan un mapa de visualización para nodos Internet. En la página personal del propio Xia Lin <<http://www.uky.edu/~xLin>> es posible encontrar más información sobre el asunto, incluyendo un conjunto de páginas Web clasificadas por este método.

5.2.2. WEBSOM

Sobre la misma línea de Xia Lin ha trabajado un grupo finlandés perteneciente al Centro de Investigación en Redes Neuronales de la Universidad Tecnológica de Helsinki, dirigido por el propio Teuvo Kohonen. El grupo desarrolló WEBSOM (Kaski, 1996; Honkela 1996a y b; Lagus, 1996), un sistema que permite ordenar automáticamente grandes masas de información en texto completo, con el fin de facilitar su exploración y navegación (*browsing*).

El potencial de este sistema ha sido demostrado en un estudio de caso donde se organiza los artículo del grupo de noticias Usenet «*comp.ai.neural-nets*». El tratamiento de este tipo de información es algo complicado debido a que, a diferencia de los mapas de Xia Lin donde se organiza información formal (artículos, ponencias, patentes, etc.), en los grupos Usenet se encuentran mensajes coloquiales, sin un formato específico, generalmente con errores ortográficos y sin corrección de estilo.




Figura 6. Generación del mapa de categoría de palabras (Kaski, 1996)

No obstante, el sistema es capaz de ordenar temáticamente de forma satisfactoria más de 4.600 mensajes que contienen cerca de 1.200.000 palabras. Para ello, utiliza un método que consta de los siguientes pasos:

- Se toman los mensajes y se elimina la información no-textual. Los códigos especiales y las expresiones numéricas son tratadas mediante reglas heurísticas.
- Para reducir el procesamiento computacional, se desestiman aquellas palabras que presentan una baja ocurrencia (menos de 50 veces) y son tratadas como entradas vacías.
- Con el fin de enfatizar el tema de cada mensaje y reducir la variaciones erráticas causadas por los diferentes estilos de discusión, se eliminan las palabras comunes que dificultan la discriminación temática. En el ejemplo de un total de 2.500 desaparecen 800.
- Con estas palabras se genera un primer mapa (SOM) de categorías de palabras (*word category map*). Estas son ordenadas en una retícula o mapa de dos dimensiones de acuerdo a sus relaciones, de forma tal que las palabras que tienden a aparecer en el mismo nodo (o en uno cercano), forman la misma categoría (figura 6).

- Este mapa es utilizado como un histograma que filtra la información de los documentos. Los autores definen al histograma como la «huella digital» de los documentos. Con la información filtrada y difuminada (*blurred*) se genera un segundo mapa (*document map*), tal como se puede apreciar en la figura 7.

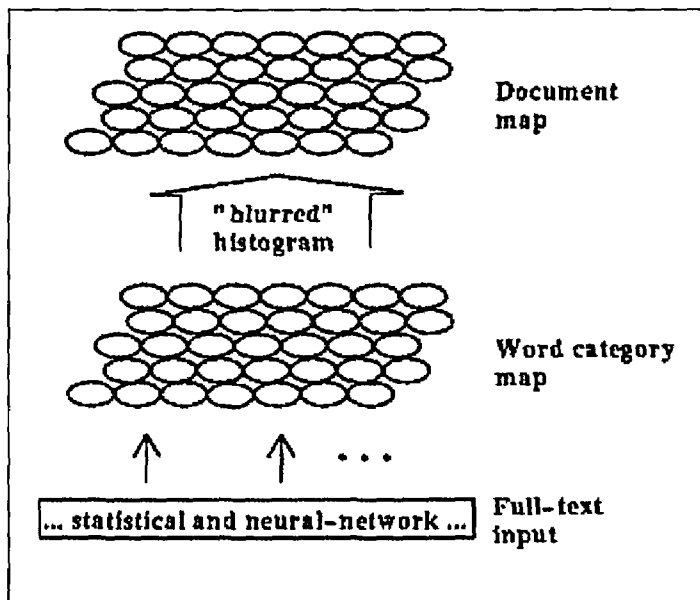


Figura 7. Generación del mapa de documentos (Kaski, 1996)

De esta forma, el producto final es un mapa como el de la figura 8, donde cada documento ocupa un lugar en el espacio en función de sus contenidos temáticos. Cada área del mapa refleja un contenido específico y los tópicos van variando levemente a lo largo del mismo. Las diferentes tonalidades indican la densidad de documentos, cuanto más oscura más documentos encontraremos.




Figura 8. Mapa global (Honkela, 1996a)

El interfase de usuario para consultar el mapa no ha sido descuidado. Este se ha implementado en HTML y permite la exploración en cuatro niveles, como se aprecia en la figura 9 (de atrás hacia delante): 1) mapa global, 2) zona aumentada, 3) mapa de nodos, y 4) vista del mensaje. El nivel 1 nos presenta un mapa sensible con la totalidad del espacio documental. Si seleccionamos una región del mismo, esta aparecerá aumentada en un mapa similar (nivel 2). En este nivel, además, es posible «moverse» hacia áreas vecinas sin necesidad de volver al mapa general y gracias a una herramienta que indica mediante flechas el rumbo a tomar. Cuando seleccionamos una región de este segundo mapa, accedemos a una lista de los mensajes o nodos de dicha región. También es posible en este nivel tras-

ladarse con las flechas de forma similar que en el nivel 2. Cuando finalmente encontramos un mensaje de nuestro agrado, simplemente lo seleccionamos y accedemos a él. Como puede observarse, la navegación a través del sistema es muy intuitiva, efectiva y sencilla. Este prototipo pueden ser visitado en <<http://websom.hut.fi/websom>>.

Finalmente, es importante destacar que para generar estos mapas es necesaria una gran potencia de cómputo. En este ejemplo los mapas han sido generados por un neurordenador masivamente paralelo CNAPS, utilizando el software SOM_PAK (Kohonen, 1996a). Este paquete es de dominio público y se encuentra disponible para las plataformas UNIX y MS-DOS en <<http://www.cis.hut.fi/nrc/nrc-programs.html>>. En dicha dirección se encuentra también un paquete de dominio público para la simulación de redes tipo LVQ (Kohonen, 1996b).

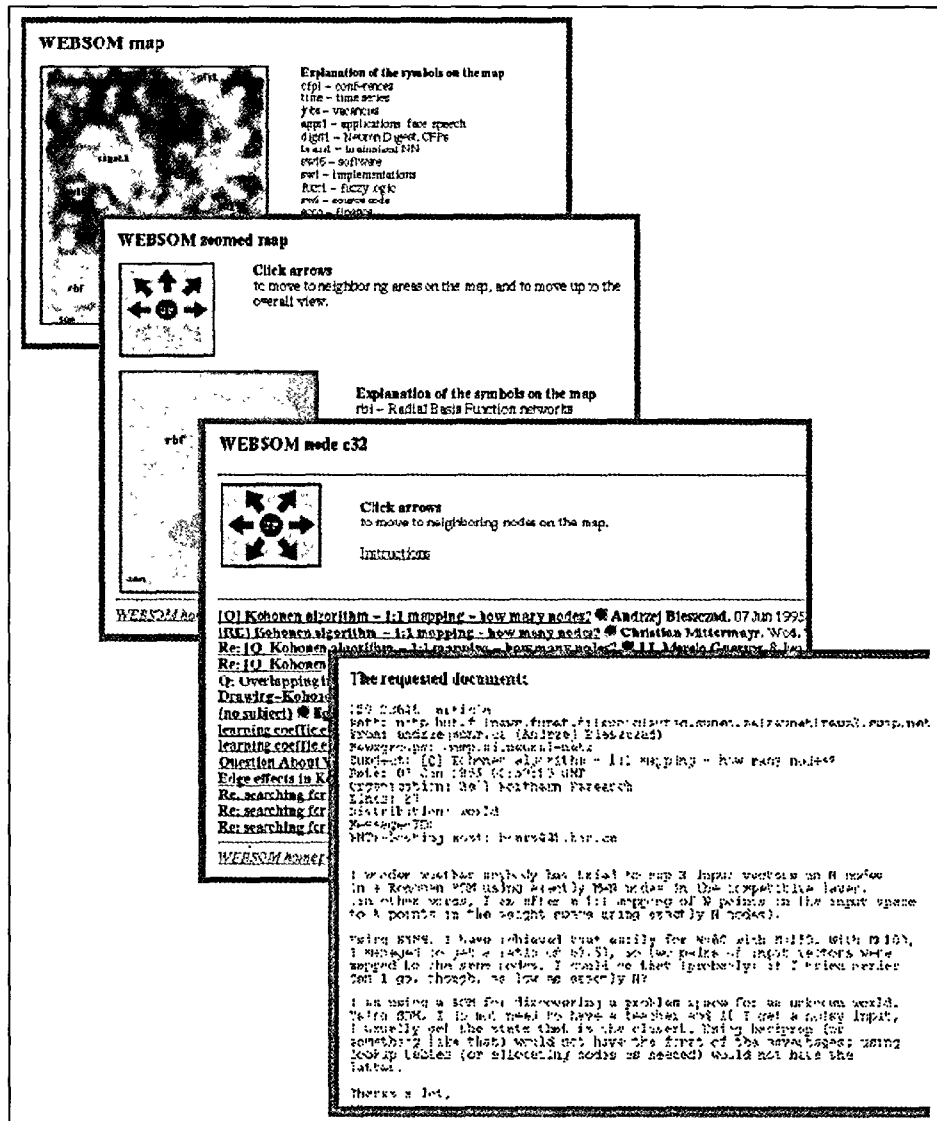


Figura 9. Los cuatro niveles del WEBSOM (Honkela, 1996a)

5.2.3. ET-Map

Este es un prototipo de un sistema de categorización de *homepages* de Internet. Ha sido desarrollado por el Grupo de Inteligencia Artificial de la Universidad de Arizona, financiado por varias entidades gubernamentales estadounidenses. El sistema intenta brindar, de forma automática y escalable, una aproximación temática a la categorización y búsqueda de información en la red.

En este proyecto se ha analizado el contenido de más de 110.000 *homepages* relacionadas con el campo del entretenimiento. Con dicha información, y valiéndose del modelo SOM de Kohonen, se construyó un mapa de dos niveles con diferentes regiones temáticas. En aquellas regiones que cuentan con más de 100 URLs, es posible acceder a un nuevo mapa más detallado. En el caso de las regiones con menos de 100 URLs, al seleccionar-

las solo se accede a una lista de ellos. El mapa se actualiza constantemente gracias a unos *spiders* o agentes que rastrean la red, de forma similar a como lo hacen los servicios de búsqueda (Altavista, Lycos, etc.). Al margen de estos detalles específicos, el sistema es muy similar a los mapas de Lin o al WEBSOM. Puede ser visitado en: <<http://ai2.BPA.arizona.edu/ent>>.

5.2.4. Mapas de EMS

Los EMS (*electronic meeting systems*) son sistemas de trabajo en grupo que integran diferentes metodologías de trabajo grupal (principalmente el *brainstorming* o «tormenta de ideas»), con el fin de optimizar la comunicación interna de una organización. Estos sistemas son muy eficientes, aunque presentan varios problemas: sobrecarga de información, dispersión de vocabulario, alta carga cognitiva, problemas de visualización de grandes bloques de información, etc. La solución a estos problemas se encuentra en la clasificación automática de la información, sin embargo, no es una solución sencilla. Orwig y Chen (1997) tras evaluar diversas técnicas de clasificación automática, se inclinan por los mapas SOM de Kohonen. Desarrollan un prototipo basado en SOM y los comparan experimentalmente con otro prototipo basado en el modelo de Hopfield.

5.2.5. Mapas de redes de publicaciones científicas

Una aplicación especial de los mapas analizados en los puntos anteriores es la organización de publicaciones científicas. El estudio de las relaciones entre las diferentes revistas de un determinado campo temático, se realiza mediante el análisis del *Journal of Citation Report* (JCR). Este repertorio, publicado por el Institute of Scientific Information (ISI), recoge las citas existentes entre diferentes títulos. Esta información es analizada con diferentes metodologías: análisis de *clusters*, escalamiento multidimensional, análisis de componentes principales, etc. Campanario propone el estudio de estas relaciones mediante la utilización del modelo de Kohonen (Campanario, 1995).

De forma similar al procedimiento de Lin, se construye un vector por cada título de revista. El vector resultante tendrá n elementos, tal que n es igual al número de títulos a analizar, y cada elemento contendrá el número de citas de cada publicación. El tamaño de la matriz de salida se calcula de acuerdo a la cantidad de títulos a analizar. Luego se entrena la red con la información de entrada y se obtiene un mapa denominado «mapa de relaciones» (*relations map*), como puede apreciarse en la figura 10-a. De forma complementaria se obtiene otro mapa denominado «mapa de dominios» (*domains map*), y que representa solamente las neuronas que se encuentran fuertemente ligadas (*strongest response*) a una determinada revista (figura 10-b).

De este modo solo aparece cada título una sola vez en el mapa. Ambos mapas son complementarios y permiten, mediante el análisis del tamaño y la proximidad de las áreas, estudiar las relaciones existentes entre dos o más revistas científicas.




Figura 10. Mapas de revistas científicas (Campanario, 1995)

5.2.6. Algoritmo de Macleod

Los mapas autoorganizativos (SOM) no constituyen el único método de clustering neuronal. Macleod ha diseñado un algoritmo específico para el *clustering* de documentos, utilizando el aprendizaje no supervisado (MacLeond, 1991). En este trabajo, las características del algoritmo son analizadas y experimentadas mediante dos pequeños tests. En base a los resultados de estos tests, se demuestra que el algoritmo de MacLeod es superior a los algoritmos de clustering jerárquico (secuencial). Por último cabe detacar que el clustering se salida es independiente del orden de entrada de los documentos.

5.3. Diseño de interfase (*interface design*)

5.3.1. ANLI: Adaptative Network Library Interface

ANLI es un programa que oficia de interfase entre el usuario de un catálogo en línea y el catálogo en sí (Kantor, 1993). El término *Network* del nombre hace mención a una red de relaciones entre los documentos, articulada mediante recomendaciones. Estas recomendaciones son aportadas por los usuarios y representan un cierto valor agregado a la información del catálogo. Podemos navegar por la red mediante una herramienta hipertextual contenida en ANLI, que permite que los diferentes usuarios compartan información mediante el «trabajo cooperativo por ordenador» (*computer-supported collaborative work*. CSCW). El sistema se basa, entre otras técnicas, en redes neuronales, pero lamentablemente Kantor no entra en detalle sobre la naturaleza y características del tipo de red utilizada. Se limita solo a decir que ANLI es una gran «red adaptativa» y que el modelo neural ha sido muy útil en el desarrollo global del sistema.

5.4. Filtrado de información (*filtering of information*)

5.4.1. Servicio Personal de Noticias (*Personal News Service*)

Los grupos de noticias Usenet (*newsgroup*) generan diariamente un volumen de información imposible de asimilar. El secreto en la utilización de estos grupos radica en la selección anticipada de los grupos y perfiles de interés mas relevantes. Aún así, la lectura de esta masa de mensajes suele ser muy ardua. Para evitar esto Jennings e Higuchi diseñaron un sistema que filtra la información Usenet y que esta basado en RNA (Jennings, 1992).

El principio de funcionamiento del sistema es bastante sencillo, como puede apreciarse en el figura 11. Al comienzo, cada artículo es analizado para extraer una serie de términos relevantes. Estos términos tienen asociado un determinado peso en función del lugar que ocupan en el mensaje (cabecera, cuerpo, *subject*, etc.), y con ellos se construye una red de relaciones. Los términos de cada nuevo mensaje son sometidos a la red, si guardan alguna correspondencia con esta, tenderán a activar o «disparar» determinados nodos, y estos a su vez podrán hacerlo con otros. En caso de que el documento genere una cierta activación, se considera que tiene la energía mínima para activar la red y por tanto es aceptado para su lectura. En el caso contrario, la energía no es suficiente y por lo tanto es desechado sin ser leído.

La red no se mantiene como una estructura fija, ya que se ve modificada por cada documento de entrada. De igual forma, con el paso del tiempo las nodos no activados tienden a perder peso, incluso pueden desaparecer. Con esto se intenta que la red sea dinámica y se adapte a las variaciones en el perfil del usuario con el transcurrir del tiempo.

Si bien esta aplicación resulta práctica e interesante, Scholtes (1995) opina que este sistema no es completamente automático, que no es adaptativo y que no explota las características típicas de la RNA: generalización y asociación.

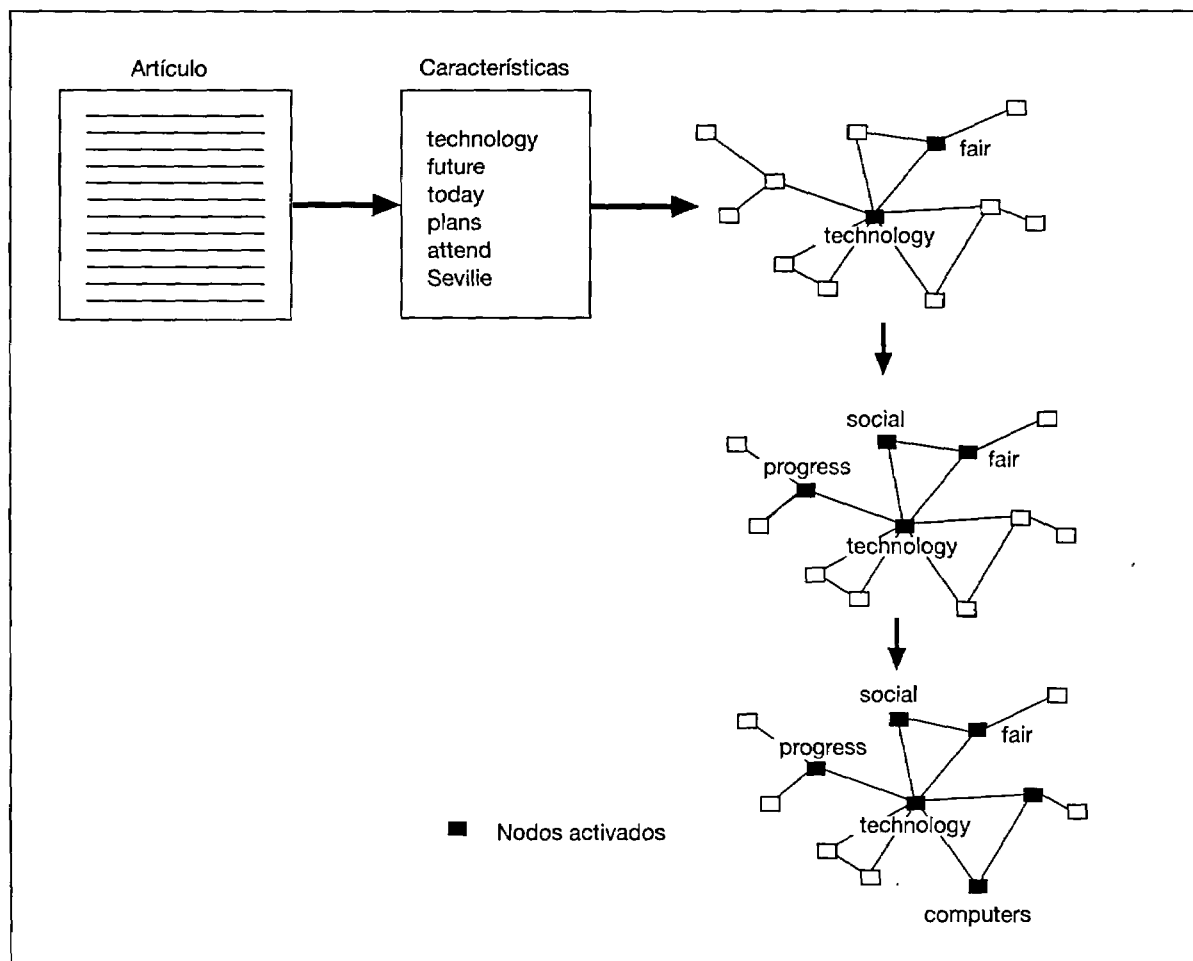


Figura 11. Esquema del servicio personal de noticias (Jennings, 1992)

5.5. Búsqueda incompleta (*incomplete searching*)

5.5.1. Proyecto Neurodoc

La búsqueda y recuperación de información mediante lenguaje natural es un campo de investigación muy importante. El grado de tolerancia a fallos tipográficos, el uso de sinónimos, etc., facilitan la relación hombre-máquina y hacen que este tipo de sistemas estén abiertos a una gama amplia de usuarios. No obstante, no podemos hablar todavía de un diálogo antropométrico con el ordenador, debido a que existen ciertos problemas aún no resueltos. El principal quizás sea la incapacidad del sistema de suplir al interlocutor humano que, conocedor de la naturaleza y alcance de la información contenida en la base de datos, permite guiar al usuario en la búsqueda de solo aquello que puede ser encontrado en la base. Con el fin de brindar una respuesta a este problema se ha desarrollado el Proyecto Neurodoc, cuyo objetivo es desarrollar un sistema de recuperación que permita la expansión de preguntas por retroalimentación (Lelu, 1991). El sistema se basa en redes neuronales, aunque no se establece claramente el tipo de topología de red utilizada. Un prototipo del sistema fue programado para entornos Macintosh (Lelu, 1992).

5.5.2. Intelligent Negotiation Neural Network (INN)

Las investigaciones en torno a la recuperación de información, indican que la búsqueda por temas es la más común y menos satisfactoria de las modalidades de búsqueda. En la misma línea que el sistema anterior y con el fin de acercar una solución al problema de la recuperación temática, se ha desarrollado el INN (Meghabghab, 1994). Este sistema se comporta como un especialista en información capaz de aprender a negociar la pregunta del usuario, con el fin de transformarla en una formulación de búsqueda correctamente construida y con mayores posibilidades de éxito.

El diseño del INN esta basado en una arquitectura de RNA multicapa que utilizan el algoritmo de retro-propagación (*back-propagation*). Se utiliza una red llamada ACN (*Attentional Connectionist Network*) para la separación de conceptos, de agentes y de relaciones, una base de conocimientos y un razonamiento analógico. La red debe ser entrenada con al menos 200 búsquedas escogidas de antemano. Una vez entrenado, el programa esta capacitado para procesar de forma inteligente las preguntas del usuario. Meghabghab no indica ningún estudio concreto sobre el rendimiento del sistema, pero afirma que mejora sensiblemente el porcentaje de éxitos para la búsqueda temática.

5.6. Descubrimiento de información (*data mining*)

Se denomina *data mining* al estudio de la recuperación de la información en condiciones adversas (mucho ruido, búsquedas incompletas), y con diversos tipos de datos (números, texto libre, registros estructurados, etc.). Como ya hemos afirmado, las RNA son sumamente útiles para el procesamiento y búsqueda de información heterogénea, incompleta y con altos niveles de ruido; por lo que estas encontraran en el *data mining* un área de aplicación muy importante (Scholtes, 1995).

5.6.1. Clementine

Este es un completo paquete de *data mining* desarrollado por la empresa Integral Solutions Ltd., y que guarda un cierto parecido con los llamados sistemas de información ejecutiva (EIS). Este producto presenta una serie de herramientas de procesamiento avanzado de la información, tales como: inducción de reglas, redes neuronales, modelos de regresión, *clustering* de información mediante redes de Kohonen (ver figura 12), análisis gráfico de la información, etc. El énfasis esta puesto en el hecho de que contar con gran cantidad de datos no nos garantiza la obtención de la información relevante. A esto también se lo denomina riqueza de datos, pobreza de información. Es por ello que el valor agregado de la información es el principal objetivo del programa, e intenta alcanzarlo mediante las siguientes funciones:

- Acceso de datos: el sistema puede acceder directamente el contenido de diversas bases de datos comerciales, tales como: Oracle, Ingres, Sybase e Informix. Puede importar datos de dichas bases y combinarlos con otros procedentes de otras aplicaciones, por ejemplo, hojas de cálculo.
- Manipulación de datos: es posible seleccionar registros mediante un criterio de búsqueda, y con ellos crear series de datos que puedan ser manipulados, exportados y procesados.
- Visualización de datos: la información puede ser vista de distintas formas, tales como, histogramas, nubes de puntos, tablas de distribución, redes de relaciones, etc. Todas las presentaciones son interactivas, pudiéndose ampliar y reducir por zonas.
- Aprendizaje: mediante las redes neuronales y la inducción de reglas es posible que el sistema «aprenda» a tomar ciertas decisiones sin supervisión humana.
- Programación visual: este es un programa complejo, no obstante, puede manejar con relativa facilidad debido a que cualquier tarea se reduce a arrastrar iconos y establecer relaciones visuales.

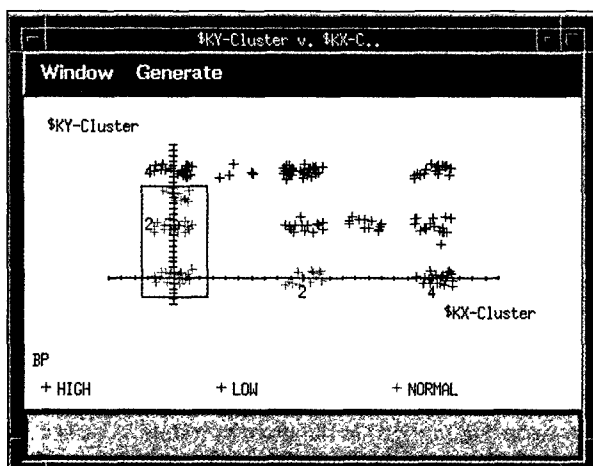


Figura 12. Clustering de información mediante redes de Kohonen <<http://www.ist.co.uk>>

El sistema no esta dirigido solamente al mundo empresarial, sino también al científico, y al cualquier ámbito donde la toma de decisiones tenga un peso importante. La empresa cuenta con una página Web que puede ser visitada en: <<http://www.isl.co.uk>>.

Conclusiones

Como hemos podido apreciar en el presente trabajo, existen varias aplicaciones que explotan las características de las RNA y las aplican al campo de la recuperación de la información. Sin embargo, se encuentran todavía limitaciones muy grandes. El principal problema consiste en el volumen de procesamiento de información necesario. Es importante tener en cuenta aquí que las RNA son un modelo del procesamiento de la información, y que los sistemas que las emulan son solo eso: emuladores de un modelo ideal.

Esta aclaración es necesaria en el caso de las RNA, debido a que la mayoría de las aplicaciones aquí citadas simulan el funcionamiento de una red masivamente paralela mediante un ordenador secuencial con arquitectura Von Neumann. Estas simulaciones no explotan la principal característica de las redes, el procesamiento paralelo, por lo que es imposible desarrollar aplicaciones que manejen masas de información reales. Solo se limitan a lo que Scholtes (1995) llama «problemas de juguete» (*toy problems*).

La solución de esta cuestión no radica en contar con máquinas secuenciales más potentes, sino con disponer de ordenadores expresamente diseñados para el cálculo paralelo masivo. La única aplicación de las aquí citadas que cuenta con un recurso de este tipo es el WEBSOM de Kohonen, que se procesa en un neurordenador CNAPS.

Otro asunto a tener en cuenta es la limitación de las RNA en cuanto a la naturaleza de la información que pueden manejar. El auge de estas técnicas puede hacer pensar que son útiles para resolver problema informativo, pero no es así. La supremacía de las RNA se aprecia a la hora de procesar información en lenguaje natural, ruidosa e incompleta. En el contexto de la recuperación de la información, es común ver aplicaciones de RNA a problemas de información estructurada, que podrían ser resueltos por otros métodos más tradicionales y fáciles de implementar (Scholtes, 1995).

A pesar de estas limitaciones las técnicas basadas en RNA aplicadas a la recuperación de la información, constituyen un campo de investigación muy prometedor que va a brindar muchos resultados a corto y medio plazo.

Bibliografía

- CAMPANARIO, J.M. (1995). «Using neural networks to study networks of scientific journals». *Scientometrics*. Vol. 33, nº 1, p. 23-40.
- CHEN, H. (1995). «Machine learning for information retrieval: neural networks, symbolic learning, and genetic algorithms». *Journal of the American Society for Information Science*. Vol. 46, nº 3, p. 194-216.
- DOSZKOCS, T.; REGGIA, J. ; LIN, X. (1990). «Connectionist models and information retrieval». *Annual Review of Information Science and Technology (ARIST)*. Vol. 25, p. 209-260.
- HAYKIN, S. (1994). *Neural networks: a comprehensive foundation*. New York: Macmillan College.
- HILERA GONZÁLEZ, J.; MARTÍNEZ HERNANDO, V. (1995). *Redes neuronales artificiales: fundamentos, modelos y aplicaciones*. Madrid: RA-MA.
- HONKELA, T.; PULKKI, V. ; KOHONEN, T. (1995). «Contextual relations of words in Grimm tales, analysed by self-organizing map». *Proceedings of International Conference on Artificial Neural Networks, ICANN-95*. París: EC2 et Cie. p. 3-7.
- HONKELA, T.; et al. (1996a). *Newsgroup exploration with WEBSOM method and browsing interface*. Espoo: Helsinki University of Technology, Laboratory of Computer and Information Science. (Technical Report, A32).
- HONKELA, T.; et al. (1996b). «Self-organizing maps of document collections». *Alma*. Vol. 1, nº 2.
- JENNINGS, A. ; HIGUCHI, H. (1992). «A browser with a neural network user model». *Library Hi Tech*. Vol. 10, nº 1-2, p. 77-93.
- KANTOR, P. (1993). «The adaptative network library interface: a historical overview and interim report». *Library Hi Tech*. Vol. 11, nº 3, p. 81-92.
- KASKI, S. ; KOHONEN, T. (1995). «Exploratory data analysis by the self-organizing map: structures of welfare and poverty in the world». En: REFENES, A.; et al. (eds.) *Neural Networks in Financial Engineering: Proceedings of the Third International Conference on Neural Networks in the Capital Markets*. London, 11-13 October, p. 498-507.

- KASKÍ, S.; et al. (1996). «Creating an order in digital libraries with self-organizing maps». En: *Proceedings of World Congress on Neural Networks, WCNN'96*. Mahwah, NJ : INNS Press. P. 814-817.
- KOHONEN, T. (1982). «Self-organized formation of topologically correct feature maps». *Biological Cybernetics*. N° 43, p. 59-69.
- KOHONEN, T.; et al. 96a). *SOM_PAK: the self-organizing map program package*. Espoo : Helsinki University of Technology, Laboratory of Computer and Information Science. (Technical Report, A31).
- KOHONEN, T.; et al. (1996b). *LVQ_PAK: the learning vector quantization program package*. Espoo : Helsinki University of Technology, Laboratory of Computer and Information Science. (Technical Report, A30).
- LARGUS, K.; et al. (1996). «Self-organizing maps of document collections: a new approach to interactive exploration». En: SIMOUNDIS, E.; HAN, J.; FAYYAD, U. (eds.) *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*. Menlo Park: AAAI Press. P. 238-243.
- LELU, A. (1991). «From data analysis to neural networks: new prospects for efficient browsing through databases». *Journal of Information Science*. N° 17, p. 1-12.
- LELU, A. ; FRANCOIS, C. (1992). «Information based on a neural unsupervised extration of thematic fuzzy clusters». *Fifth International Conference of Neural Networks and their Aplications, Neuro Nimes '92*. Nimes (Francia), 2-6 November. P. 93-104.
- LIN, X.; LIEBSCHER, P. ; MARCHIONINI, G. (1991). «Graphical representations of electronic search patterns». *Journal of the American Society for Information Science*. Vol. 42, n° 7, p. 469-478.
- LIN, X. (1995). «Searching and browsing on map displays». *Proceedings of ASIS'95*. Chicago, October. P. 13-18.
- LIN, X. (1997). «Map displays for information retrieval». *Journal of the American Society for Information Science*. Vol. 48, n° 1, p. 40-54.
- MCCULLOCH, W. ; PITTS, W. (1943). «A logical calculus of the ideas immanent in nervous activity». *Bulletin of Mathematical Biophysics*. N° 5, p. 115-133.
- MACLEOD, K. ; ROBERTSON, W. (1991). «A neural algorithm for document clustering». *Information Processing & Management*. Vol. 27, n° 4, p. 337-346.
- MEGHABGHAB, G. ; MEGHABGHAB, D. (1994). «INN: an intelligent negotiation neural network for information systems: a design model». *Information Processing & Management*. Vol. 30, n° 5, p. 663-685.
- MINSKY, M. ; PAPERT, S. (1969). *Perceptrons*. Cambrige : MIT Press.
- ORWIG, R.; CHEN, H. ; NUNAMAKER, J. (1997). «A graphical, self-organizing approach to classifying electronic meeting output». *Journal of the American Society for Information Science*. Vol. 48, n° 2, p. 157-170.
- PATTERSON, D. (1995). *Artificial neural networks: theory and applications*. New York : Prentice Hall.
- PÉREZ, E. (1991). «Neural network applications for library management». *Library Software Review*. Vol. 10, n° 5, p. 349-350.
- REGUEIRO, C.; et. al. (1995). «Modelos básicos de redes neuronales artificiales». En: BARRO, S.; MIRA, J. (eds.) *Computación neuronal*. Santiago de Compostela : Universidade, Servicio de Publicacións e Intercambio Científico. (Cursos e Congresos da Universidade de Santiago de Compostela, 86).
- SCHOLTES, J. (1995). *Artificial neural networks for information retrieval in libraries context*. Luxembourg: European Commision. (Libraries in the Information Society).
- RAAN, A.F.J. VAN ; TIJSSEN, R.J.W. (1993). «The neural net of neural network research: an exercise in bibliometric mapping». *Scientometrics*. Vol. 26, n° 1, p. 169-192.
- WILKINSON, R. ; HINGSTON, P. (1992). «Incorporating the vector space model in neural network used for document retrieval». *Library Hi Tech*. Vol. 10, n° 1-2, p. 69-75.
- ZIMMER, U.; FISCHER, C.; PUTTKAMER, E. VON (1994). «Navigation on topologic feature-maps». *Proceedings of the 3rd. International Conference on Fuzzy Logic, Neural Nets and Soft Computing*. Iizuka (Japón), August 1-7. P. 131-132.